

Project 2. MiniGPT

实验报告

训练完成时间：2026-07-07 · wandb run: `skypile5m-6L256D-b128` · [在线日志](#)

1. 实验概述

从零实现了 decoder-only mini-GPT（BPE + RoPE + KV cache），在 **SkyPile 50 万条** 中文网页语料上完成预训练。最终 dev 困惑度 **7.39**（阈值 < 100），三项自检全部通过，产出 `ckpt/best.pt` 与 `ckpt/tokenizer.json`。

2. 数据集

项目	内容
来源	SkyPile 子集
规模	500,000 条（全量约 2.33 亿网页 / 620 GB）
划分	9:1 → train.txt（1.2 GB）+ dev.txt（136 MB）
训练方式	StreamingTokenBlockDataset：每 step 随机读 ≤ 8 KB 文档，避免全量 token 化 OOM

3. 模型与超参数

本次在 README 默认小模型（4L/128D）基础上放大了一档，以更好利用 RTX 3090 显存：

类别	参数	取值
模型	层数 / 头数 / 隐层维度	6 / 8 / 256
	词表 / 上下文长度	512 / 256
	dropout / 参数量	0.1 / ~ 4.86M
优化	优化器 / 学习率 / weight decay	AdamW / 3e-4 / 0.01
	调度	warmup 2000 step + cosine 衰减
	grad clip	1
训练	epoch / batch size	10 / 128
	steps/epoch / 总 step	2000 / 20,000
	BPE 语料上限	≤ 2 MB / ≤ 2000 篇文档
硬件	GPU / 总耗时	RTX 3090 × 1 / ~ 13.2 h


实际启动命令：

```

1  CUDA_VISIBLE_DEVICES=0 python train.py --device cuda \
2  --epochs 10 --n-layer 6 --n-head 8 --n-embd 256 \
3  --batch-size 128 --warmup-steps 2000 \
4  --log-every 100 --sample-every 2 \
5  --reuse-tokenizer --wandb-run-name skypile5m-6L256D-b128

```

4. 训练曲线



Epoch	train_loss	dev_ppl
1	3.64	14.49
2	2.72	10.26
5	2.37	7.95
8	2.28	7.5
10	2.26	7.39

每个 epoch 约 79 min (2000 step × ~2.4 s/step)。dev 困惑度单调下降，末 epoch 仍略有改善，尚未明显过拟合。

5. 自检结果

`python eval/run.py` 输出 (详见 `eval/result.json`)：

测试	结果	备注
tokenizer_roundtrip	通过	中文 encode/decode 无损
kv_cache_equivalence	通过	最大 logits 差 8.6e-06
perplexity_on_dev	通过	PPL 7.39 < 100

6. 生成样例

以「床前明月光」为 prompt (top-p=0.9, temperature=0.8, 32 token)：

Epoch	生成片段
2	床前明月光识，被《天猫父光》期间猫独光
5	(未采样)
8	床前明月光线，首次在未来两年突破2100万元的大型
10	床前明月光明，现在普通人的选择和课程却是非常重要的，...

早期生成语义不通顺；后期已能产出连贯的中文网页风格片段，但仍存在重复、乱码 (🔍) 等典型小模型问题。

7. 小结

- **完成度**： `src/` 六模块 + 训练循环均已实现；SkyPile 50 万预训练与自检通过。
- **关键设计**：RoPE 替代绝对位置编码；KV cache 用于增量推理；BPE 仅取 train 前 2 MB 训练词表，大语料用 streaming 训练。
- **可改进方向**：增大模型/语料、延长 epoch；BPE 训练语料可适度扩大；生成质量可用更大 top-k 或 repetition penalty 调优。

数据档位参考

数据集	命令	规模	适用场景
唐诗 quick-start	--dataset poetry	~48 KB	5 分钟跑通代码
SkyPile 50 万（推荐）	--dataset skypile --num-samples 500000	~1.3 GB	3090 正式训练
SkyPile 10 万	--dataset skypile	~280 MB	快速实验
TinyStories	--dataset tinystories	百 MB 级	英文叙事实验
SkyPile 500 万	--num-samples 5000000	~13 GB	❌ BPE 阶段 OOM，勿用

脚本统一生成 `data/train.txt`、`data/dev.txt`、`data/dataset_info.json`。

实现约定

文件	必须导出
src/ tokenizer.py	class BPETokenizer 含 encode、decode、vocab_size、from_pretrained
src/ model.py	class MiniGPT 含 forward、generate、block_size / max_seq_len、load_for_eval
ckpt/tokenizer.json	训练好的 BPE 词表
ckpt/ best.pt	dev 困惑度最优 checkpoint