

Project 5. Conan Tool Agent

任务五实验报告：Conan Agent（工具调用 / ReAct）

填写说明：把所有 [待填] 换成你的内容；不需要的可选节可删。
建议提交到 [nndl-discussion](#) 时附上本报告 + `eval/result.json` + 1~2 段完整 trace。

项目	内容
姓名 / 学号	24300810019 Gary Agasa
完成日期	2026.7.16
代码仓库 / 分支	https://github.com/garyagasa/LLM_beginner/tree/master/Project5_tool-agent
自检命令	python eval/ run.py

1. 实验概述

用 2~4 句话概括你做了什么、主题是什么、最终自检是否通过。

示例写法：

本实验实现了一个名侦探柯南主题的 ReAct 工具调用 Agent：**五个工具**（计算器、Python 沙箱、档案检索、维基百科、柯南 Wiki）+ **手写 Thought/Action/Observation 循环**，**本地用 vLLM 部署 Qwen2.5 模型**，**在 28 题任务集上评测关键词命中率**。

2. 环境与模型部署

项目	取值
GPU	[待填，如 RTX 3090 × 1, CUDA_VISIBLE_DEVICES=1]
推理引擎	vLLM / Ollama / 其他: [待填]
模型	[待填，如 Qwen/Qwen2.5-7B-Instruct]
API	OPENAI_BASE_URL= [待填]
依赖	pip install -r requirements.txt + [待填: vllm 版本等]

启动命令（可贴实际用的）：

代码块

```
1 # [待填] 例如:
2 export HF_ENDPOINT=https://hf-mirror.com
3 bash scripts/serve_vllm.sh
```

冒烟结果（可选）：

```
(llm_pj5)
1 # 用一句话介绍江户川柯南
2 curl http://localhost:8000/v1/models
3 python -c "from src.llm import chat; print(chat([{'role':'user','content':'用一
  句话介绍江户川柯南'}]))"
```

代码块

```
1 {"object":"list","data":[{"id":"Qwen/Qwen2.5-7B-Instruct","object":"model","created":1784212763,"owned_by":"vllm","root":"Qwen/Qwen2.5-7B-Instruct","parent":null,"max_model_len":8192,"permission":[{"id":"modelperm-64e550add99648c9898600879004a299","object":"model_permission","created":1784212763,"allow_create_engine":false,"allow_sampling":true,"allow_logprobs":true,"allow_search_indices":false,"allow_view":true,"allow_fine_tuning":false,"organization":"*", "group":null,"is_blocking":false}]]}]
2 柯南·德坡尔是一位才华横溢但命运多舛的年轻侦探。
```

3. 系统设计

3.1 整体流程

用文字或简图说明 ReAct 循环：




图 12.1 ReAct 式的思考-行动-观察循环

- 1 用户任务
- 2 → system prompt (人设 + 工具列表 + few-shot)
- 3 → LLM 生成 Thought / Action / Action Input
- 4 → call_tool → Observation 写回历史
- 5 → ... 直至 Final Answer 或步数上限
- 6 → 返回 AgentTrace {steps, final_answer, success}

3.2 工具一览

工具名	文件	作用	实现要点 (各 1 句)
calculator	src/tools/ calculator.py	[待填]	[待填：如 AST 白名单]
python_sandbox	src/tools/ python_sandbox.py	[待填]	[待填：受限 builtins / 超时 / stdout]
file_search	src/tools/ file_search.py	[待填]	[待填：越界保护]
wiki	src/tools/ wiki.py	[待填]	[待填]
conan_wiki	src/tools/ conan_wiki.py	[待填]	[待填：Fandom API / User-Agent]

wiki vs conan_wiki 的路由原则 (写进 prompt 的那句) : [待填]

3.3 Prompt 设计

- 人设: [待填]
- few-shot 条数与内容概要: [待填，如：APTX 年龄差用 calculator；查灰原哀用 conan_wiki]
- 输出格式约束: Thought / Action / Action Input / Final Answer
- 你认为最有效的一条 prompt 技巧: [待填]

4. 实现说明 (按模块)

4.1 M1 工具

各工具遇到的坑与解决办法 (没有可写「顺利」) :

代码块

```
1 python -c "from src.tools.calculator import run; print(run({'expression': '2 + 3 * 4'}))"
2 python -c "from src.tools.calculator import run; print(run({'expression': '17-7'}))"
```

4.1.1 Calculator工具

算式求值（年龄差、4869 算术、sqrt/log10）

代码块

```
1 python -c "from src.tools.python_sandbox import run; print(run({'code':  
    'print(sum(range(10)))'}))"
```

代码块

```
1 14  
2 10
```

4.1.2 python sandbox工具

跑一小段受限 Python，抓 `print` 输出

代码块

```
1 python -c "from src.tools.python_sandbox import run; print(run({'code':  
    'print(sum(range(10)))'}))"
```

代码块

```
1 45
```

4.1.3 file search工具

在本地目录按文件名/内容搜档案

功能

- 文件名匹配：支持 glob（如 `*.md`）和子串匹配（如 `README.md`）
- 内容关键词：对 不含 `.` 的 pattern（如 `APT4869`、`琴酒`）在文件内容中搜索
- 路径安全：解析后的路径必须仍在 `dir` 下；跳过隐藏目录和 `pycache`
- 资源限制：最多扫描 5000 个文件，单文件最大 512KB
- 输出格式：相对路径 + 可选 snippet

代码块

```
1 python -c "from src.tools.file_search import run; print(run({'pattern':  
    'README.md', 'dir': '.'}))"
```

```
2 python -c "from src.tools.file_search import run; print(run({'pattern':  
'APT4869', 'dir': 'data/agent-fixtures'}))"
```

代码块

- 1 README.md | snippet: Conan Tool Agent > 主大纲见仓库根 [README](../README.md); 本目录是该任务的资源、自检与提交入口。 ![logo](/assets/logo.png) 实现 ReAct 循环, 让 LLM 自主调用工具...
- 2 data/agent-fixtures/README.md | snippet: 米花町档案室 · 任务五本地检索夹具。 本目录是毛利侦探事务所整理的主线速查柜: APTX4869、黑衣组织、红方 (FBI/公安/CIA)、宫野家、赤井家、毛利家与少年侦探团等。 ## 怎么用 - 用 `file\_search` 按文件

代码块

- 1 README.md | snippet: 花町档案室 · 任务五本地检索夹具。 本目录是毛利侦探事务所整理的主线速查柜: APTX4869、黑衣组织、红方 (FBI/公安/CIA)、宫野家、赤井家、毛利家与少年侦探团等。 ## 怎么用 - 用 `file\_search` 按文件名或关键...
- 2 aptx4869_dossier.md | snippet: # APTX4869 档案 (事务所速查) > 加粗年龄数字为本任务夹具约定, 供计算器/沙箱题稳定作答; 与动画具体集数有出入时, 以本文件为准, wiki 作补充。
基本资料
- 3 black_org_roster.md | snippet: 灭口 - 特征: 长银发、黑衣、常驾车; 性格冷酷多疑 - 主线: 强迫工藤新一服用 APTX4869 的关键人物; 多次接近柯南却未完全识破 - 搭档: 伏特加 ### 伏特加 (Vodka) - 职位: 琴酒的行动搭档 - 特征: 墨镜、体型壮硕; 相对...
- 4 cipher_todo.md | snippet: # 暗号草稿 TODO - TODO: 核对 APTX4869 与「夏洛克」谐音是否写进结案报告。 - TODO: 红黑双方名单勿泄露给贝尔摩德线相关人员。 - TODO: 朗姆目击描述互相矛盾, 单独建疑点表 (假眼 / 轮
- 5 detective_allies.md | snippet: 所 ### 江户川柯南 (工藤新一) - 真实身份: 高中生侦探工藤新一, 服用 APTX4869 后缩小 - 寄住: 毛利家; 对外称「远房亲戚」 - 手段: 麻醉手表、变声蝶领带, 借毛利小五郎之口破案 - 目标: 找回身体、揭露黑衣组织、保护身边人 ...
- 6 main_plot_notes.md | snippet: 。 1. **游乐场事件**: 工藤新一跟踪黑衣组织交易, 被琴酒发现, 强迫服下 APTX4869, 身体缩小。 2. **江户川柯南诞生**: 新一化名寄住毛利家, 开始双重生活。 3. **宫野明美之死**: 灰原的姐姐欲脱离组织, 被琴酒杀害。 4...
- 7 miyano_line.md | snippet: 衣组织有研究合作 - 研究线索: 银色子弹 (Silver Bullet) — 与 APTX4869 前身/相关项目有关 - 结局: 两人都已故; 给志保留下录音等关键遗产情报 ## 宫野明美 - 身份: 志保的姐姐; 曾为组织做事 (含抢夺资金等任务) ...
- 8 red_side_roster.md | snippet: 角色摘要 | | --- | --- | | 工藤新一 / 江户川柯南 | 被 APTX4869 缩小后, 以小学生身份追查组织 | | 灰原哀 | 叛逃科学家; 提供组织与药物情报; 协助研制解药 | | 世良真纯 | 女侦探; 赤井家相关; 行动...

4.1.4 wiki工具

查现实维基百科

代码块

```
1 python -c "from src.tools.wiki import run; print(run({'query': '柯南·道尔'})[:300])"
```

代码块

```
1 [zh Wikipedia: 柯南道尔]
2 亞瑟·伊格内修斯·柯南·道爾爵士，KStJ，DL（英語：Sir Arthur Ignatius Conan Doyle；1859年5月22日–1930年7月7日），是英国小說家、醫生。因塑造成功偵探人物——福爾摩斯，而成為偵探小说作家。除此之外還寫過多部其他類型的小說，如科幻、歷史、爱情小说、戲劇、詩歌等。
```

4.1.5 conan wiki工具

查柯南中文wiki(Fandom)

代码块

```
1 python -c "from src.tools.conan_wiki import run; print(run({'query': '灰原哀'})[:1000])"
```

代码块

```
1 灰原哀(宮野志保) 首次登場 漫畫第18冊、動畫第136集；劇場版第3集 配音 林原惠 魏晶琦 [ 1 ]
; 許雲雲 [ 2 ] 曾秀清 ; 羅杏芝 閻萌萌 年齡 18歲(外表年齡7歲) [ 3 ] 性別 女 國籍 日本 (宮野志保) 无国籍 (灰原哀) 職業 科學家、小學生 灰原哀 親人 宮野厚司 (父) 宮野艾雷娜 (母) 宮野明美 (姊姊) (皆已故) paux2 Sherry (台譯「雪莉」) paux3 帝丹小學1年B班 paux4 褐色 paux5 米花町2號街22號(阿笠博士家) paux2 name 組織代號 paux3 name 班級 paux4 name 髮色 paux5 name 住所 aux1 《愛因斯坦的光榮與苦惱的日子》 [ 4 ] aux2 花生醬 和 藍莓 果醬 夾心三明治 ( Peanut butter and jelly sandwich , ピーナッツバターとゼリーのサンドイッチ ) [ 5 ] aux3 比護、BIG大阪隊 aux4 PRADA (普拉達) 的新款皮包 [ 6 ]、芙紗繪品牌的新款錢包 [ 7 ] divider yes aux1 name 喜歡的電影aux2 name 喜歡的食物 aux3 name 喜歡的球星以及球隊 aux4 name 喜歡的奢侈品 灰原哀 (日文: 灰原 哀 ( はいばら あい ) ; 罗马字表記: Haibara Ai ) , 本名宮野志保 (日文: 宮野 志保 ( みやの しほ ) ; 罗马字表記: Miyano Shiho ) , 原为 黑衣组织 的成员雪莉, 是 APTX-4869 的发明者。在姐姐 宮野明美 遭组织杀害后, 志保因反抗组织而被囚禁, 欲服下APTX-4869自杀, 没想到身体竟意外缩小, 反倒帮她摆脱了组织控制。在寻找有类似遭遇的工藤新一帮助时, 志保得到了 阿笠博士的帮助, 从此开始寄宿于博士的家中, 并和化名 江户川柯南 的工藤新一一起在 帝丹小学 一年B班 就读。 [ 8 ] 目录 1 概要 2 人物特點 3 研發的藥品 4 其他 5 参考资料 概要 [ ] 本名 宮野志保 , 是日英 混血儿 與「 APTX-4869 」研發者 [ 9 ]、; 父亲是人称“被科学界放逐的疯狂科学家”的 宮野厚司 , 母亲是人称“墮落地獄的天使”的英國人 宮野艾蓮娜 ; 两人都是 黑暗组织 的
```

4.2 M2 ReActAgent

- **解析策略**: 正则提取 Thought / Action / Action Input / Final Answer ; Final Answer 优先视为终止。

- **Action Input:** 优先 `json.loads`；若包在 markdown 代码块中先剥离；失败则保留原始字符串并包装为 `{"input": ...}`。
- **终止条件:** 解析到 `Final Answer` 立即返回；或达到 `max_steps` 返回 `success: False`。
- **格式失败重试:** 缺少 `Action` 时追加 user 消息提示按格式输出，不中断循环。
- **trace 字段:** 每步写入 `thought` / `action` / `action_input` / `observation` / `tool`（与 `action` 相同，供 eval 统计）。

4.3 M3 错误恢复

- **是否实现** `enable_error_injection`：是。
- **注入策略:** 第一次真实工具调用替换为 `Error: simulated tool failure`，之后正常调用。
- **恢复率:** 专用测试题通过（`injected=true`，`retried=true`，`recovered=true`）；Agent 在失败后重试 calculator 并给出含 `48690` 的最终答案。

4.4 M4 Qwen-Agent 对照

- **是否完成:** 是（`src/qwen_agent_baseline.py`）。
- **成功率对比**（28 题完整跑分，`eval/qwen_baseline_result.json`；与 `eval/run.py` 同脚本逻辑，因 LLM 非完全确定性，ReAct 成功率可能在 78%~82% 之间波动）：

方案	成功率	命中题数
手写 ReAct	78.60%	22/28
Qwen-Agent	89.30%	25/28
差值	+10.7 pp	+3 题

- **差异观察:**
 - a. Qwen-Agent 使用原生 **function calling**，无需模型维护 ReAct 文本格式，题 1、5、8 等「多步计算 / 综合问答」更稳定。
 - b. 两者在 **file_search 计数题（题 3）** 和 **关键词精确匹配题（题 10、14）** 上均失败——根因是模型数错 `.md` 文件数、Final Answer 未出现「米花町」「姐姐」等评测关键词，而非工具本身故障。
 - c. 手写 ReAct 偶发**步数耗尽仍输出 Action**（题 8），暴露纯文本解析的脆弱性。

5. 自检结果

代码块

```
1 python data/download.py # 生成 tasks.json + agent-fixtures
```

测试项	结果	摘要
tools_individual	通过	calculator / python_sandbox / file_search / wiki / conan_wiki 全部 True
multi_tool_success_rate	通过	82.1% (23/28) ，高于 60% 线
error_recovery	通过	注入后重试成功

按题型粗分（ReAct，28 题）：

类型	约题数	表现
纯计算（calculator）	~10	9/10，题 1 漏答「10」
Python 沙箱	~5	5/5,都对
本地档案（file_search）	~8	5/8，题 3 计数错、题 10/14 关键词未命中
网络百科（wiki / conan_wiki）	~8	7/8，题 5 缺 APTX 关系描述
多工具组合	~12	多数成功，失败集中在「要同时满足多个关键词组」的题

完整明细见 eval/result.json。

6. 案例分析（至少 2 个）

6.1 成功案例（题 19：多工具链）

任务原文：

查柯南百科「琴酒」，确认他属于黑衣组织；再计算组织最爱的数字梗：4+8+6+9 等于多少？

调用工具序列： conan_wiki → calculator

最终答案：

琴酒属于黑衣组织，组织特别喜欢的数字 4、8、6、9 的和为 27。

完整 trace（缩略）：

代码块

```
1 Thought: 先查柯南百科确认琴酒阵营，再计算 4+8+6+9。
2 Action: conan_wiki
3 Action Input: {"query": "琴酒"}
4 Observation: ...琴酒（Gin）...黑衣组织高层...
5
```



```
6 Thought: 已确认属于黑衣组织，计算数字之和。
7 Action: calculator
8 Action Input: {"expression": "4+8+6+9"}
9 Observation: 27
10
11 Thought: 信息已齐全，可以作答。
12 Final Answer: 琴酒属于黑衣组织，组织特别喜欢的数字 4、8、6、9 的和为 27。
```

6.2 失败 / 有趣案例（题 1：关键词漏答）

任务原文：

【真相计算】APT_X 档案里新一真实年龄 17、外表 7。请计算 17 - 7，并告诉我 4869 乘以这个年龄差等于多少。

调用工具序列： `calculator` → `calculator` （工具选对且结果正确）

最终答案：

4869乘以新一的真实年龄和外表年龄的差值等于48690。

错在哪： 计算过程正确，但 Final Answer 未显式写出年龄差「10」；评测用子串匹配，「48690」不含「10」，故判失败。属于答案表述不完整，非工具或推理错误。

若改进 prompt： 增加「Final Answer 须逐条回应题目中的每一个小问，关键中间结果（如年龄差）也要写出」。预期题 1 类失败可消除。

7. 对比实验

实验： M4 手写 ReAct vs Qwen-Agent（同模型、同 28 题、同工具实现）

指标	ReActAgent	Qwen-Agent
成功率	78.60%	89.30%
共同失败题	3, 10, 14	3, 10, 14
ReAct 独败	1, 5, 8 等	—
Qwen 独成	—	1, 5, 8 等

简要结论： 在同工具、同模型下，框架原生 function calling 比手写文本 ReAct 高约 11 个百分点，主要优势在格式稳定和多步工具链；两者在 file_search 计数与关键词精确命中上表现相近，说明瓶颈已从「会不会调工具」转向「答案是否覆盖评测关键词」。

8. 收获与不足

- 收获（知识点）：
- 1. 理解了 ReAct 循环如何把 **Thought / Action / Observation** 拼进多轮对话，以及工具异常应回写为 Observation 而非抛异常中断。
 - 2. 实践了 OpenAI function calling schema 设计与 **AST 白名单**、路径越界保护等工具安全写法。
 - 3. 对比 Qwen-Agent 与手写 Agent，体会到**文本格式解析与原生 tool call** 在可靠性上的差距。
- 不足与下一步：
- 1. Final Answer 经常漏写中间关键词（题 1、10），需在 prompt 或后处理中强制「逐问作答」。
 - 2. file_search 计数题（题 3）模型常少数文件；可在 prompt 中提示 `pattern: "*.md"` 并教其逐行计数 Observation 行数。
 - 3. 尚未做 Qwen-Agent 与 ReAct 的**逐步 trace 级对比**和错误注入在 Qwen 侧的恢复实验。

9. 提交清单

- ✓ 本报告 (`report.md`)
- ✓ `eval/result.json`
- ✓ 关键代码路径说明 (`src/agent.py`、`src/tools/*`、`src/qwen_agent_baseline.py`)
- ✓ 至少 1 段完整成功 trace (见 §6.1)
- ✓ M4 对比表 (见 §4.4、§7; 明细 `eval/qwen_baseline_result.json`)

附录 A：目录结构

```
代码块
1  Project5_tool-agent/
2  |— report.md                # 本报告
3  |— scripts/serve_vllm.sh
4  |— src/
5  |   |— agent.py            # M2 ReAct + M3 错误注入
6  |   |— qwen_agent_baseline.py # M4 对照
7  |   |— config.py / llm.py
8  |   |— tools/
9  |— data/agent-fixtures/    # 柯南档案柜
10 |— data/tasks.json         # 28 题
11 |— eval/result.json        # 必检结果
12 |— eval/qwen_baseline_result.json # M4 对照结果
```

附录 B：参考

- ReAct: <https://arxiv.org/abs/2210.03629>
- Qwen-Agent: <https://github.com/QwenLM/Qwen-Agent>
- 柯南中文 Wiki: <https://detectiveconan.fandom.com/zh/wiki>
- 本仓库 README / `eval/tutor_prompt.md`